课时内容

第8章人工神经网络与连接学习

◆ 人工神经元的结构及模型

2. 人工神经网络的分类

- 按拓扑结构
  - 前馈网络
  - 反馈网络
- 按学习方法
  - 有导师指导
  - 无导师指导
- 按网络性能
  - 连续型网络
  - 离散型网络
- 按网络层级
  - 浅层网络
  - 深层网络

8 人工神经网络的互联结构

◆ 人工神经元的互联结构

人工神经网络的互连结构（或称拓扑结构）是指单个神经元之间的连接模式，它是构造神经网络的基础，也是神经网络诱发偏差的主要来源。

从互连结构的角度，人工神经网络可分为前馈网络和反馈网络两种类型。

1. 前馈网络
（只包含前向联结）

- **单层前馈网络**：仅含输入层和输出层，且只有输出层的神经元是可计算节点

$$y_j = f\left(\sum_{i=1}^{n} w_{ij} x_i - \theta_j\right) \qquad j = 1,2,\dots, m$$

- **多层前馈网络**：除拥有输入、输出层外，还至少含有一个、或更多个隐含层的前向网络

2. 反馈网络
（可含有反馈联结）

- **单层反馈网络**：指不拥有隐含层的反馈网络
- **多层反馈网络**：指拥有隐含层的反馈网络

◆ 人工神经元的结构及模型

■ 反馈神经网络

反馈网络是指允许采用反馈联结方式所形成的神经网络。所谓反馈联结方式是指一个神经元的输出可以被反馈至同层或前层的神经元。

反馈网络和前向网络区别：

前向网络属于非循环连接模式，它的每个神经元的输入都没有包含该神经元先前的输出，因此不具有“短期记忆”的性质。

反馈网络则不同，它的每个神经元的输入都有可能包含有该神经元先前输出的反馈信息，即一个神经元的输出是由该神经元当前的输入和先前的输出这两者来决定的，这就有点类似于人类的短期记忆的性质。

◆单层感知器(3/7)

使用**感知器的主要目的是为了对外部输入进行分类**。

已经证明，如果外部输入是线性可分的（指存在一个超平面可以将它们分开），则单层感知器一定能够把它划分为两类。其判别超平面由如下判别式确定：

$$\sum_{i=1}^{n} w_{ij} x_i - \theta_j = 0 \qquad j = 1,2,\dots, m$$

作为例子，下面讨论用单个感知器实现逻辑运算的问题。

事实上，单层感知器可以很好地实现“与”、“或”、“非”运算，但却不能解决“异或”问题。

◆单层感知器(4/7)：与

输入		输出	超平面	阈值条件
x_1	x_2	$x_1 \wedge x_2$	$w_1 * x_1 + w_2 * x_2 - \theta = 0$	
0	0	0	$w_1 * 0 + w_2 * 0 - \theta < 0$	$\theta > 0$
0	1	0	$w_1 * 0 + w_2 * 1 - \theta < 0$	$\theta > w_2$
1	0	0	$w_1 * 1 + w_2 * 0 - \theta < 0$	$\theta > w_1$
1	1	1	$w_1 * 1 + w_2 * 1 - \theta \geq 0$	$\theta \leq w_1 + w_2$

可以证明此表有解，例如取$w_1=1$，$w_2=1$，$\theta=1.5$，其分类结果如图所示。

其中，输出为1的用实心圆，输出为0的用空心圆。后面约定相同。

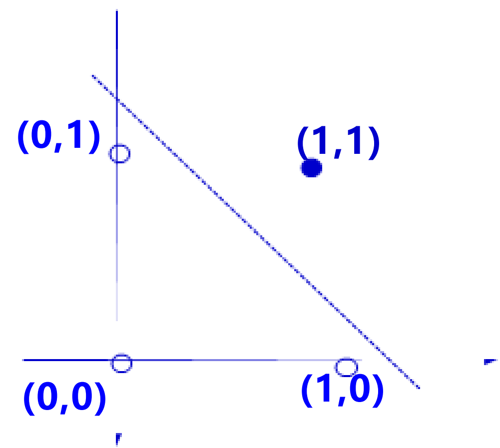

与运算问题图示

8 感知器模型

◆单层感知器(5/7)：或

输入		输出	超平面	阈值条件
x_1	x_2	$x_1 \vee x_2$	$w_1{}^*x_1+ w_2{}^* x_2-\theta=0$	
0	0	0	$w_1{}^*0+ w_2{}^*0 - \theta < 0$	$\theta > 0$
0	1	1	$w_1{}^*0+ w_2{}^*1 - \theta \geq 0$	$\theta \leq w_2$
1	0	1	$w_1{}^*1+ w_2{}^*0 - \theta \geq 0$	$\theta \leq w_1$
1	1	1	$w_1{}^*1+ w_2{}^*1-\theta \geq 0$	$\theta \leq w_1+ w_2$

此表也有解，例如取w_1=1，w_2=1，θ=0.5，其分类结果如右图所示。

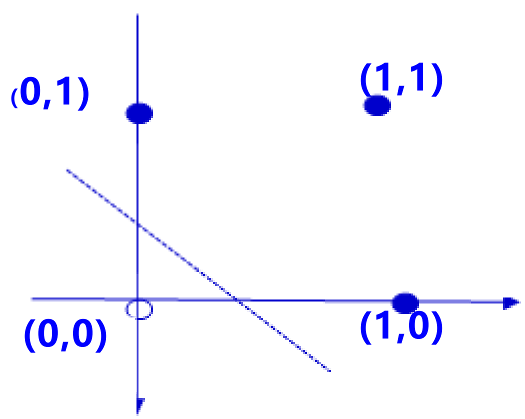

或运算问题图示

◆单层感知器(6/7)：非

例8.3 “非”运算（$\neg x_1$）

输入	输出	超平面	阈值条件
x_1	$\neg x_1$	$w_1*x_1-\theta=0$	
0	1	$w_1*0-\theta\geq 0$	$\theta\leq 0$
1	0	$w_1*1-\theta<0$	$\theta>w_1$

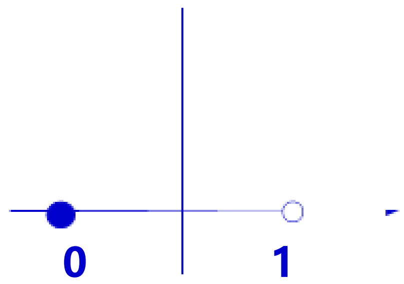

非运算分类结果

此表也有解，例如取w_1=-1，θ=-0.5，其分类结果如图所示。

◆单层感知器(7/7)

例8.4 “异或”运算（x_1 XOR x_2）

输入		输出	超平面	阈值条件
x_1	x_2	x_1 XOR x_2	$w_1*x_1+w_2*x_2-\theta=0$	
0	0	0	$w_1*0+w_2*0-\theta<0$	$\theta>0$
0	1	1	$w_1*0+w_2*1-\theta\geq0$	$\theta\leq w_2$
1	0	1	$w_1*1+w_2*0-\theta\geq0$	$\theta\leq w_1$
1	1	0	$w_1*1+w_2*1-\theta<0$	$\theta>w_1+w_2$

此表无解，即无法找到满足条件的w_1、w_2和θ，如图所示。**因为异或问题是一个非线性可分问题，需要用多层感知器来解决。**

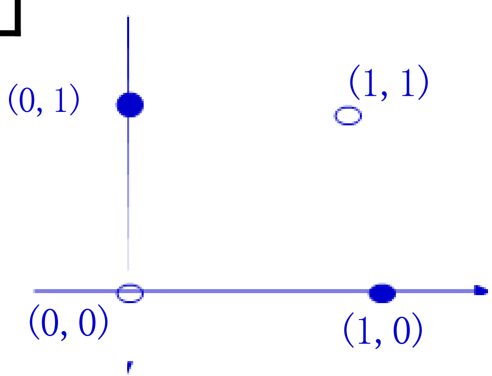

“异或” 运算问题

◆ 深度卷积神经网络的基本结构

深度卷积神经网络

Overview

↓

convolution | *pooling*

↓

sparse connectivity | *parameter sharing* | *equivariant representation*

↓

卷积层--*convolution* | 池化层--*pooling* | 全连接层—*fully connected*

◆ 深度卷积神经网络的基本结构

深度卷积神经网络

CNN的一个重要操作卷积是CNN的核心思想，就是这个卷积有效的提取了图像特征用于后面的图像识别。

右图就是一个2维卷积的示意图，这里因为是离散的卷积，所以可以直接把卷积理解为矩阵相乘，即两个矩阵相乘，一个是输入矩阵，一个是卷积核矩阵。输入矩阵一般都表示二维的输入图像，而卷积核其实可以理解为图像处理里面的算子，比如这些算子可以实现一些边缘检测或者高斯模糊的效果，那么其实卷积操作可以理解为对图像进行一些特征处理。

如图所示，一个卷积操作就是指卷积核和同样大小的一个图像矩阵相乘，然后再向下或者向右滑动卷积核，执行下一个卷积操作。这样用卷积核在整个图像上面滑动一遍便生成了一个卷积层。

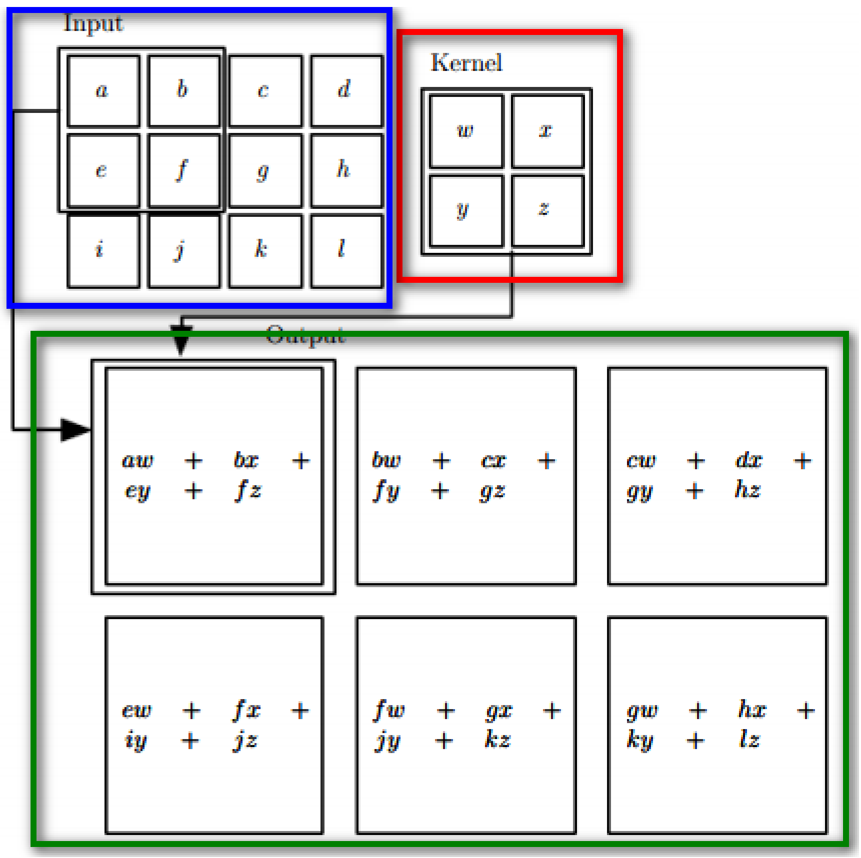

◆ 深度卷积神经网络的基本结构

深度卷积神经网络

正是由于卷积核的存在，而且卷积核的大小比整幅图像小，所以才产生了稀疏连接这样的思想。全连接的像右图下面蓝色框表示
把卷积核就想成连接权，这时卷积核和图像大小相同，相当于全连接，所以输出层中的s_3收到输入层所有神经元的影响。

再看红色框里面的连接方式，可以把图像想象成二维的，这里只展示出了一维信息，而卷积核是3乘3大小的，所以就产生了连接权的稀疏性，即最终s_3只受到了三个神经元的影响。

根据一些生物学的研究视觉感知细胞其实是局部感知的
比如用很小的卷积核来提取整幅图像的布局边缘信息，这时候采用全连接的意义并不大，不能学到很好的图像特征信息，而且模型复杂度还很高。

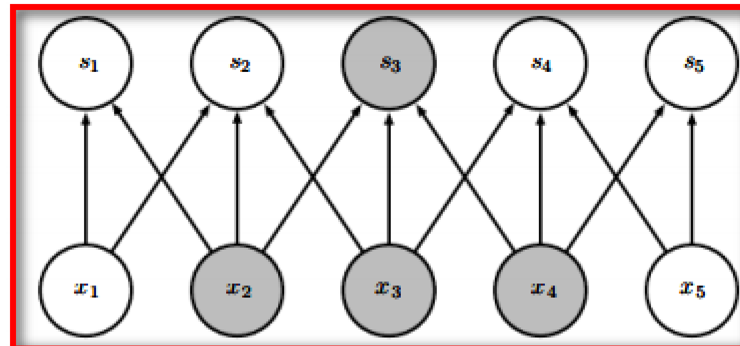

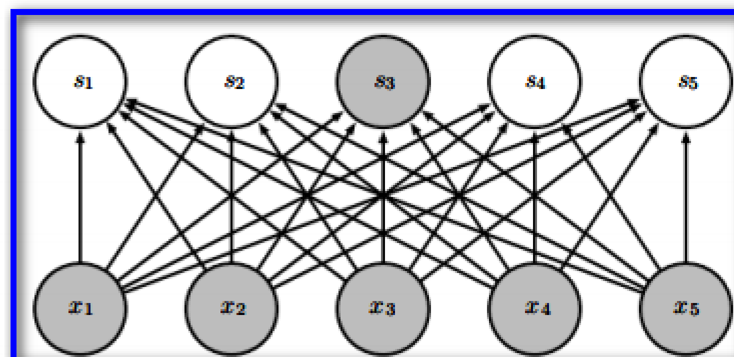

上图中红色框里面的表示稀疏连接
上图中蓝色框里面表示非稀疏连接

◆ 深度卷积神经网络的基本结构

深度卷积神经网络

第一部分降到的卷积核在整幅图像上滑动其实就是一种权值共享，因为这里的卷积核代表的其实就是权值，而这个权值用于了整幅图像从而产生了下一层网络，也就是说对于图像的每个局部位置，它们连接到下一层的权值都是一样的-**权值共享**。

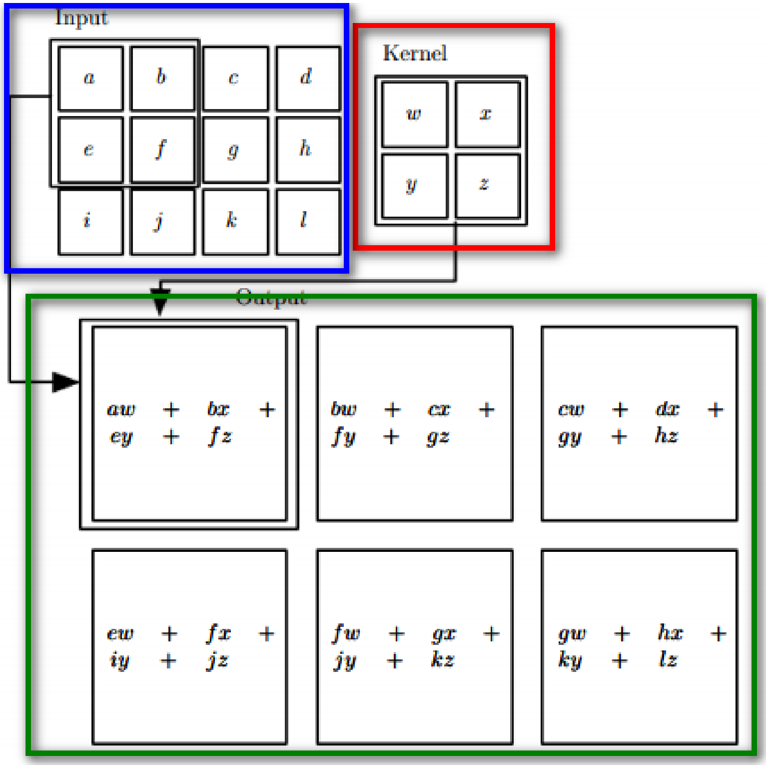

8 深度卷积神经网络

◆ 深度卷积神经网络的基本结构

深度卷积神经网络

pooling操作是指在生成卷积层以后，图像某块区域的值被这个区域内所有值得统计量所取代，例如*max pooling*操作就是把一个矩形局域内最大的输出当做这块区域的输出。当然还有其他的pooling function，比如average pooling，weighted average pooling等

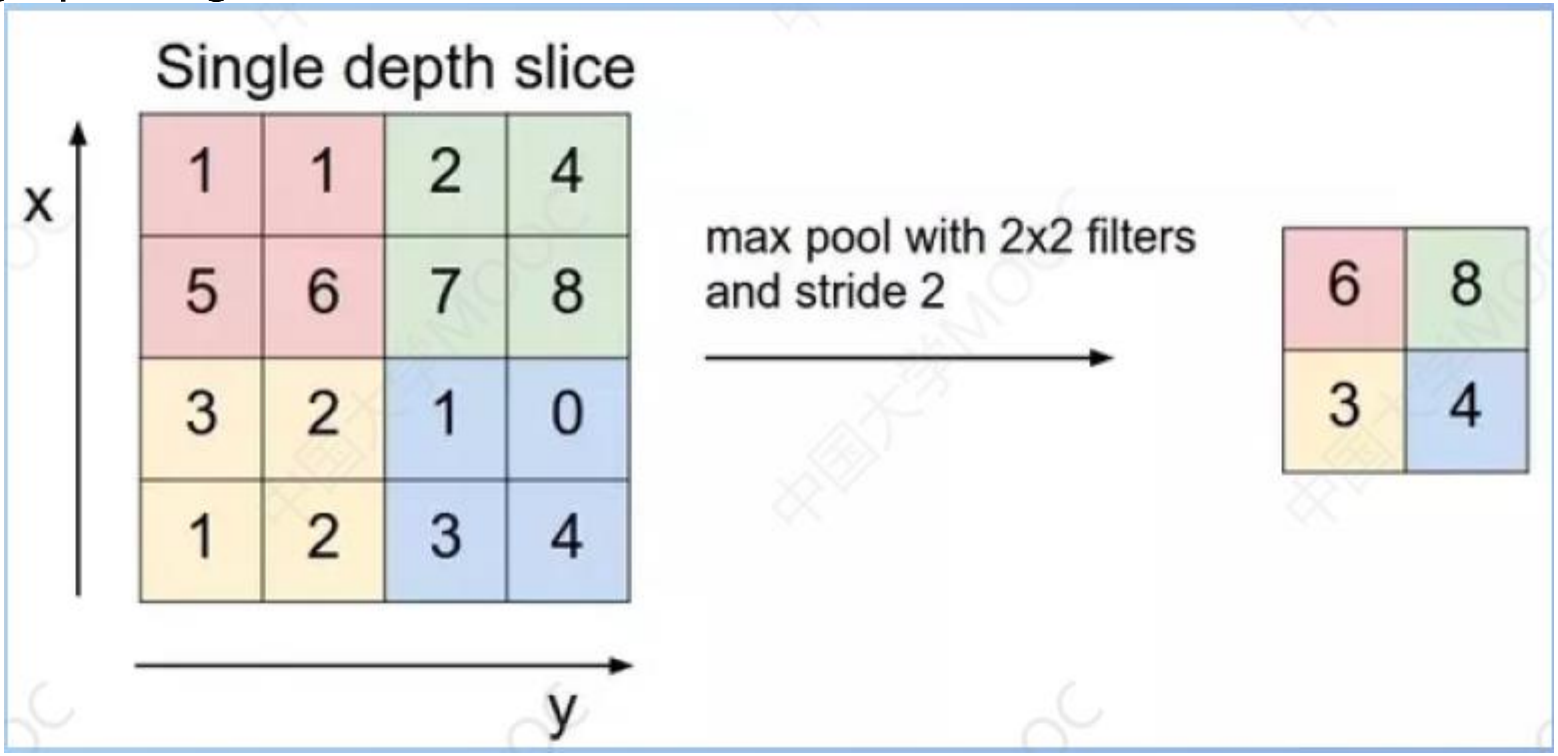

连接学习规则

1.Hebb学习规则

连接学习规则可简单地理解为学习过程中神经元之间联结权值及神经元自身阈值的调整规则。按照学习规则，神经学习可分为Hebb学习、纠错学习、竞争学习及随机学习等。

Hebb学习的基本思想

如果神经网络中某一神经元同另一直接与它连接的神经元同时处于兴奋状态，那么这两个神经元之间的连接强度将得到加强，反之应该减弱。其对连接权值的调整可表示为:

$$w_{\mathrm{ij}}(t+1)=w_{\mathrm{ij}}(t)+\eta[x_i(t)x_j(t)]$$

其中，$w_{\mathrm{ij}}(t+1)$表示时刻t的权值修正一次后所得到的新的权值;

η是一正常量，也称为学习因子，它取决于每次权值的修正量;

$x_i(t)$、$x_j(t)$分别表示t时刻第i个和第j个神经元的状态。

Hebb学习分析

Hebb学习是联结学习中影响较大的一种学习方法，认为对神经元重复同以刺激就可以产生性质相同、程度增强的反应。

2.纠错学习规则

纠错学习也叫误差修正学习，是一种有导师的学习过程。

基本思想：利用神经网络的期望输出与实际输出之间的偏差作为连接权值调整的参考，并最终减少这种偏差。

误差修正规则：连接权值的变化与神经元希望输出和实际输出之差成正比。其联结权值的计算公式为:

$$w_{\mathrm{ij}}(t+1)=w_{\mathrm{ij}}(t)+\eta[\mathrm{d}_j(t)-y_j\ (t)]x_i(t)$$

其中，$w_{\mathrm{ij}}(t)$表示时刻t的权值；$w_{\mathrm{ij}}(t+1)$表示对时刻t的权值修正一次后所得到的新的权值；η是一正常量，也称为学习因子；$y_j\ (t)$为神经元j的实际输出; $\mathrm{d}_j(t)$为神经元j的希望输出；$\mathrm{d}_j(t)-y_j\ (t)$表示神经元j的输出误差，$x_i(t)$为第i个神经元的输入。

学习过程:

①选择一组初始$w_{\mathrm{ij}}(0)$；

②计算某一输入模式对应的实际输出与期望输出的误差；

③按上述公式更新权值；

④返回②，直到误差满足要求为止。

8 连接学习规则

3.竞争学习规则

基本思想：竞争中获胜神经元的连接权会向着对其刺激相应模式更为有利的方向发展；而竞争失败神经元的刺激响应模式受到抑制。

学习过程：竞争型学习的简单形式是任一时刻只允许一个神经元被激活

①将一个输入模式送给输入层LA；

②将LA层神经元的激活值送到下一层LB；

③LB层神经元对LA层送来的刺激模式进行竞争，每个神经元将一个正信号送给自己（自兴奋反馈），同时将一个负信号送给该层其它神经元（横向邻域抑制）；

④LB层中输出值最大的神经元为竞争获胜神经元，该神经元被激活，连接权值增强；其它神经元为竞争失败神经元，受到抑制，连接权则不变。

4.随机学习规则

基本思想:

结合随机过程、概率和能量（函数）等概念来调整网络的变量，从而使网络的目标函数达到最大（或最小）。

网络变化规则:

① 如果网络变量的变化能使能量函数有更低的值，那么就接受这种变化;
② 如果网络变量变化后能量函数没有更低的值，那么就按某一预先选取的概率分布接受这一变化。

分析:

随机型学习不仅可以接受能量函数减少（性能改善）的变化，而且还可以以某种概率分布接受使能量函数增大（性能变差）的变化。

模拟退火算法就是一种典型的随机学习算法。

8 感知器学习

1. 单层感知器学习算法(1/2)

感知器学习可分为单层感知器和多层感知器，这里先讨论单层感知器的学习算法，至于多层感知器学习算法，后面给出其说明。

假设X(k)和W(k)分别表示学习算法在第k次迭代时输入向量和权值向量，为方便，把阈值θ作为权值向量W(k)中的第一个分量，对应地把“-1”固定地作为输入向量X(k)中的第一个分量。即W(k)和X(k)可分别表示如下：

$$X(k) = [-1, x_1(k), x_2(k), \dots, x_n(k)]$$

$$W(k) = [\theta(k), w_1(k), w_2(k), \dots, w_n(k)]$$

即$x_0(k) = -1$， $w_0(k) = \theta(k)$。

单层感知器学习是一种有导师学习，它需要给出输入样本的期望输出。

假设一个样本空间可以被划分为A、B两类，定义:

功能函数：若输入样本属于A类，输出为+1，否则其输出为-1。

期望输出：若输入样本属于A类，期望输出为+1，否则为-1（或0）。

1.单层感知器学习算法(2/2)

单层感知器学习算法可描述如下：

(1)设$t=0$，初始化连接权和阈值。即给$w_i(0)$(i=1，2，… ,n)及$\theta(0)$分别赋予一个较小的非零随机数，作为初值。其中，$w_i(0)$是第0次迭代时输入向量中第i个输入的连接权值；$\theta(0)$是第0次迭代时输出节点的阈值；

(2)提供新的样本输入$x_i(t)$(i=1, 2, … , n)和期望输出d(t)；

(3)计算网络的实际输出：

$$y(t)=f\left(\sum_{i=1}^{n} w_i(t)x_i(t)-\theta(t)\right) \qquad i=1,2,\ldots,n$$

(4)若$y(t)=d(t)$，不需要调整连接权值，转(6)。否则，需要调整权值

(5)调整连接权值

$$w_i(t+1)=w_i(t)+\eta[d(t)-y(t)]x_i(t) \qquad i=1,2,\ldots,n$$

其中，η是一个增益因子，用于控制修改速度，其值如果太大，会影响$w_i(t)$的收敛性；如果太小，又会使$w_i(t)$的收敛速度太慢;

(6)判断是否满足结束条件，若满足，算法结束；否则，将t值加1，转(2)重新执行。这里的结束条件一般是指$w_i(t)$对一切样本均稳定不变。

若输入的两类样本是线性可分的，则该算法就一定会收敛。否则，不收敛。

2.单层感知器学习的例子(1/4)

例6.5 用单层感知器实现逻辑“与”运算。

解：根据“与”运算的逻辑关系，可将问题转换为：

输入向量：

$$X_1 = [0, 0, 1, 1]$$
$$X_2 = [0, 1, 0, 1]$$

输出向量：

$$Y = [0, 0, 0, 1]$$

为减少算法的迭代次数，设初始连接权值和阈值取值如下：

$$w_1(0) = 0.5, w_2(0) = 0.7, \theta(0) = 0.6$$

并取增益因子$\eta = 0.4$。

算法的学习过程如下：

设两个输入为$x_1(0) = 0$和$x_2(0) = 0$，其期望输出为$d(0) = 0$，实际输出为：

$$y(0) = f(w_1(0)x_1(0) + w_2(0)x_2(0) - \theta(0))$$
$$= f(0.5 * 0 + 0.7 * 0 - 0.6) = f(-0.6) = 0$$

实际输出与期望输出相同，不需要调节权值。

2.单层感知器学习的例子(2/4)

再取下一组输入：$x_1(0)=0$和$x_2(0)=1$， 期望输出$d(0)=0$，实际输出：

$$y(0)=f(w_1(0)x_1(0)+w_2(0)x_2(0)-\theta(0))$$
$$=f(0.5*0+0.7*1-0.6)=f(0.1)=1$$

实际输出与期望输出不同，需要调节权值，其调整如下：

$$\theta(1)=\theta(0)+\eta(d(0)-\ y(0))*(-1)=0.6+0.4*(0-1)*(-1)=1$$
$$w_1(1)=w_1(0)+\eta(d(0)-\ y(0))x_1(0)=0.5+0.4*(0-1)*0=0.5$$
$$w_2(1)=w_2(0)+\eta(d(0)-\ y(0))x_2(0)=0.7+0.4*(0-1)*1=0.3$$

取下一组输入：$x_1(1)=1$和$x_2(1)=0$，其期望输出为$d(1)=0$，实际输出为：

$$y(1)=f(w_1(1)x_1(1)+w_2(1)x_2(1)-\theta(1))$$

$$=f(0.5*1+0.3*0-1)=f(-0.51)=0$$

实际输出与期望输出相同，不需要调节权值。

2.单层感知器学习的例子(3/4)

再取下一组输入：$x_1(1)=1$和$x_2(1)=1$，其期望输出为$d(1)=1$，实际输出为：

$$y(1)=f\big(w1(1)x1(1)+\ w2(1)x2(1)-\theta(1)\big)$$
$$=f(0.5*1+0.3*1-1)=f(-0.2)=0$$

实际输出与期望输出不同，需要调节权值，其调整如下：

$$\theta(2)=\theta(1)+\eta(d(1)-\ y(1))*(-1)=1+0.4*(1-0)*(-1)=0.6$$
$$w_1(2)=w_1(1)+\eta(d(1)-\ y(1))x_1(1)=0.5+0.4*(1-0)*1=0.9$$
$$w_2(2)=w_2(1)+\eta(d(1)-\ y(1))x_2(1)=0.3+0.4*(1-0)*1=0.7$$

取下一组输入：$x_1(2)=0$和$x_2(2)=0$，其期望输出为$d(2)=0$，实际输出为：

$$y(2)=f(0.9*0+0.7*0-0.6)=f(-0.6)=0$$

实际输出与期望输出相同，不需要调节权值。

2.单层感知器学习的例子(4/4)

再取下一组输入：$x_1(2)=0$和$x_2(2)=1$，期望输出为$d(2)=0$，实际输出为：$y(2)=f(0.9*0+0.7*1-0.6)=f(0.1)=1$

实际输出与期望输出不同，需要调节权值，其调整如下：

$$\theta(3)=\theta(2)+\eta(d(2)-\ y(2))*(-1)=0.6+0.4*(0-1)*(-1)=1$$
$$w_1(3)=w_1(2)+\eta(d(2)-\ y(2))x_1(2)=0.9+0.4*(0-1)*0=0.9$$
$$w_2(3)=w_2(2)+\eta(d(2)-\ y(2))x_2(2)=0.7+0.4*(0-1)*1=0.3$$

实际上，由上一章关于与运算的阈值条件可知，此时的阈值和连接权值以满足结束条件，算法可以结束。

对此，可检验如下：

对输入：“0 0”有y=f(0.9*0+0.3*0-1)=f(-1)=0

对输入：“0 1”有y=f(0.9*0+0.3*1-1)=f(-0.7)=0

对输入：“1 0”有y=f(0.9*1+0.3*0-1)=f(-0.1)=0

对输入：“1 1”有y=f(0.9*1+0.3*1-1)=f(0.2)=1

课时内容

第9章 卷积神经网络

9 卷积神经网络的构成

◆ 卷积神经网络

- **是一种前馈神经网络**
- **受生物学上感受野（Receptive Field）的机制而提出的**

　在视觉神经系统中，一个神经元的感受野是指视网膜上的特定区域，只有这个区域内的刺激才能够激活该神经元。

- **卷积神经网络有三个结构上的特性：**

✓ 局部连接

✓ 权重共享

✓ 空间或时间上的次采样

◆卷积神经网路常用的损失函数

- 平均绝对误差损失函数（Mean Absolute Error）也被称为损失函数，用于计算神经网络输出值与真实值之间误差的平均绝对值大小，常用于处理回归问题

$$MAE = \frac{1}{N}\sum_{i=1}^{n}|y_i - \hat{y}_i|$$

公式中y_i是神经网络预测值，$\hat{y}_i$是真实值

◆卷积神经网路常用的损失函数

- 均方差损失函数（Mean Squared Error）用于度量神经网络输出值与实际值差的平方期望值，均方差损失函数可以很好用于度量数据的变化程度。其公式如下所示：

$$MSE = \frac{1}{N}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2$$

其中，N表示样本的总量，均方差损失函数是常用于回归问题的损失函数。